



การทำนายค่าฝุ่น PM2.5 กรุงเทพมหานคร ด้วยเทคนิค Multiple Linear Regression

จัดทำโดย

ณัฐพงศ์	กัลยารัตน์	1660700327
กัญญาณัฐ	สุดเชยชม	1660700974
พิชญุตม์	มารมย์	1660701085
วรินทร์	จงกลรัตน์	1660701101
กษิรา	สาริमानนท์	1660701234
เบญญา	เป็งเขื่อน	1660701341
อาภรณ์ภัทร์	ปานช้าง	1660701473

อาจารย์ผู้สอน

อาจารย์ วิชัย สุขสิริเจริญกุล

หลักสูตรวิทยาศาสตร์บัณฑิต

ภาคการศึกษาที่ 2 ปีการศึกษา 2567

เอกสารนี้เป็นส่วนหนึ่งของวิชา CS462 Data Analytics and Mining

ภาควิชาวิทยาการคอมพิวเตอร์ คณะเทคโนโลยีสารสนเทศและนวัตกรรม

สารบัญ

บทนำ

- วัตถุประสงค์
- เครื่องมือที่ใช้

บทที่ 1

- Data Collection

บทที่ 2

- Data Preprocessing

บทที่ 3

- Model Training

บทที่ 4

- Model Evaluation

บทที่ 5

- สรุปโครงงาน

บทนำ

Project Overview and Objective ปัญหาฝุ่นละอองขนาดเล็ก PM2.5 เป็นวิกฤตด้านสิ่งแวดล้อมที่ส่งผลกระทบต่อสุขภาพประชาชนในกรุงเทพมหานครอย่างต่อเนื่องทุกปี โดยเฉพาะในช่วงฤดูหนาวและฤดูแล้ง (ธันวาคม–เมษายน) ที่ค่าฝุ่นมักพุ่งสูงเกินเกณฑ์มาตรฐานขององค์การอนามัยโลก (WHO) การติดตามและพยากรณ์ค่าฝุ่นล่วงหน้าจึงมีความสำคัญอย่างยิ่งในการวางแผนป้องกันสุขภาพสาธารณะ

โครงการนี้เป็นส่วนหนึ่งของวิชา CS462 Data Analytics and Mining มีวัตถุประสงค์เพื่อประยุกต์ใช้กระบวนการ Data Science ตั้งแต่การรวบรวมข้อมูล การเตรียมข้อมูล การฝึกโมเดล Machine Learning การวัดผล และการสรุปผลเชิงวิเคราะห์ให้เกิดประโยชน์ได้จริง หัวข้อที่เลือกคือ การทำนายค่าฝุ่น PM2.5 ในกรุงเทพมหานครด้วยเทคนิค Multiple Linear Regression โดยใช้ข้อมูลคุณภาพอากาศย้อนหลัง 7 ปี (2557–2564) ครอบคลุม 2,624 วัน จากสถานีตรวจวัดคุณภาพอากาศกรุงเทพมหานคร โดยมีตัวแปรต้น ได้แก่ PM10, O3, NO2, SO2 และ CO เพื่อทำนายค่า PM2.5

หัวข้อนี้ถูกเลือกด้วยเหตุผลสำคัญ 3 ประการ ได้แก่ ความเกี่ยวข้องกับปัญหาจริงที่คนไทยเผชิญอยู่ทุกปี ความพร้อมของข้อมูลสาธารณะ (Public Data) ที่มีคุณภาพ และความเหมาะสมของโมเดล Linear Regression ที่สามารถอธิบายความสัมพันธ์เชิงสาเหตุระหว่างก๊าซมลพิษต่าง ๆ กับค่าฝุ่นได้อย่างตีความได้ (Interpretable) ซึ่งสำคัญในบริบทของนโยบายสาธารณสุข

วัตถุประสงค์

- สร้างโมเดล Machine Learning ที่สามารถทำนายค่า PM2.5 จากค่ามลพิษอื่นๆ ได้
- ศึกษาความสัมพันธ์ระหว่างก๊าซมลพิษต่างๆ กับค่าฝุ่นละอองขนาดเล็ก
- ประเมินความแม่นยำของโมเดลด้วย R^2 , RMSE และ MAE
- นำองค์ความรู้จากชั้นเรียน (Linear Regression, Feature Engineering) มาประยุกต์ใช้กับข้อมูลจริง

เครื่องมือที่ใช้

- Python (Google Colab) ภาษาโปรแกรมหลัก
- pandas, numpy จัดการและประมวลผลข้อมูล
- scikit-learn สร้างและประเมินโมเดล
- matplotlib, seaborn แสดงผลกราฟและ Dashboard

บทที่ 1

Data Collection

1.1 แหล่งข้อมูล

ข้อมูลที่นำมาใช้ในโครงการนี้คือ ไฟล์ bangkok-air-quality.csv ซึ่งรวบรวมข้อมูลคุณภาพอากาศรายวันของกรุงเทพมหานคร จากแหล่งข้อมูล IQAir และกรมควบคุมมลพิษ สถานีตรวจวัดคุณภาพอากาศ กรุงเทพฯ

1.2 โครงสร้างข้อมูล

ภายในชุดข้อมูลที่ใช้เป็นข้อมูลที่ถูกเก็บเป็นระยะเวลา 2624 วัน ตั้งแต่ช่วงวันที่ 31 ธันวาคม 2556 ถึง 14 มีนาคม 2564 (ประมาณ 7 ปี) ตารางข้อมูลมีขนาด 2,624 แถว (1 แถว = 1 วัน) และมี 7 คอลัมน์ โดยแต่ละคอลัมน์มีการเก็บข้อมูลแต่ละประเภท ดังนี้

#	Column	ความหมาย	หน่วย	ประเภท / Dtype	Non-Null Count	หมายเหตุ	บทบาทในโมเดล
0	date	วันที่บันทึก	dd/mm/yyyy	datetime64[ns]	2,624 non-null	วันที่บันทึกข้อมูล	ใช้สร้าง Time features (month, season)
1	pm25	ฝุ่นละออง ≤ 2.5 µm	µg/m³	float64	1,680 non-null	TARGET ค่าที่ต้องการทำนาย	TARGET (y) ค่าที่โมเดลทำนาย
2	pm10	ฝุ่นหยาบ ≤ 10 µm	µg/m³	float64	2,609 non-null	ฝุ่นหยาบ Feature สำคัญที่สุด	Feature สำคัญที่สุด (coef = 30.34)
3	o3	โอโซน (Ozone)	µg/m³	float64	2,610 non-null	ก๊าซโอโซนระดับพื้นดิน	Feature ปฏิกริยาเคมีในอากาศ
4	no2	ไนโตรเจนไดออกไซด์	µg/m³	float64	2,611 non-null	ก๊าซจากท่อไอเสียรถยนต์	Feature ตัวชี้วัดการจราจร
5	so2	ซัลเฟอร์ไดออกไซด์	µg/m³	float64	1,877 non-null	ก๊าซจากโรงงานอุตสาหกรรม	Feature ก๊าซจากโรงงาน
6	co	คาร์บอนมอนอกไซด์	µg/m³	float64	963 non-null	ก๊าซคาร์บอนมอนอกไซด์	Feature การเผาไหม้

ความหมายของค่ามลพิษแต่ละตัว:

- PM25 (ฝุ่นละออง): ฝุ่นขนาด ≤ 2.5 ไมครอน คือค่าที่โมเดลต้องการทำนาย
- PM10 (ฝุ่นหยาบ): ฝุ่นขนาด ≤ 10 ไมครอน มาจากฝุ่นถนน เขม่าควัน เป็น Feature สำคัญที่สุด เพราะมีความสัมพันธ์สูงกับ PM2.5
- O3 (โอโซน): ก๊าซโอโซนระดับพื้นดิน เกิดจากแสงแดดทำปฏิกิริยากับ NOx บ่งบอกถึงปฏิกิริยาเคมีในอากาศ
- NO2 (ไนโตรเจนไดออกไซด์): มาจากท่อไอเสียรถยนต์เป็นหลัก ใช้ชี้วัดระดับการจราจร
- SO2 (ซัลเฟอร์ไดออกไซด์): มาจากโรงงานอุตสาหกรรมและการผลิตไฟฟ้า
- CO (คาร์บอนมอนอกไซด์): เกิดจากการเผาไหม้ไม่สมบูรณ์ บ่งชี้ปริมาณการเผาไหม้ในพื้นที่

1.3 สถิติพรรณนา (df.describe)

	pm25	pm10	o3	no2	so2	co	หมายเหตุ
count	1,680	2,609	2,610	2,611	1,877	963	จำนวนแถวที่ไม่ว่าง
mean	86.17	39.19	19.48	14.56	3.15	9.29	ค่าเฉลี่ย
min	26.00	11.00	1.00	1.00	1.00	2.00	ค่าต่ำสุด
25%	62.00	26.00	11.00	9.00	1.00	7.00	Q1
50%	77.00	36.00	16.50	13.00	2.00	9.00	Median
75%	105.00	50.00	25.00	18.00	4.00	11.00	Q3
max	187.00	128.00	119.00	72.00	64.00	37.00	ค่าสูงสุด
std	31.97	16.64	12.76	8.16	3.61	3.75	ส่วนเบี่ยงเบนมาตรฐาน

บทที่ 2

Data Preprocessing

2.1 การตรวจสอบค่าว่าง (Missing Values)

Column	Non-Null	Missing	% Missing	วิธีการจัดการ
date	2,624	0	0%	ไม่มีค่าว่าง
pm25	1,680	944	36%	ทิ้งแถวที่ pm25 = NaN (เป็น Target)
pm10	2,609	15	0.6%	SimpleImputer (strategy=median)
o3	2,610	14	0.5%	SimpleImputer (strategy=median)
no2	2,611	13	0.5%	SimpleImputer (strategy=median)
so2	1,877	747	28%	SimpleImputer (strategy=median)
co	963	1,661	63%	SimpleImputer (strategy=median)

ผลกระทบและวิธีแก้ไข:

- pm25 ขาด 944 แถว ทิ้งแถวที่ pm25 = NaN เพราะเป็น Target ไม่สามารถ impute ได้ ทำให้มีข้อมูลสำหรับเทรนโมเดล 1,680 แถว
- co ขาด 63% ถ้าลบคอลัมน์ทิ้งจะเสียข้อมูลที่มีคุณค่า จึงใช้ SimpleImputer (strategy=median) เติมค่ากลาง ข้อเสียคือค่าที่เติมอาจไม่ตรงความเป็นจริง ควรระวังในการตีความ
- so2 ขาด 28% ใช้ SimpleImputer (strategy=median) เช่นกัน
- pm10, o3, no2 ขาดน้อยกว่า 1% ใช้ SimpleImputer (strategy=median) เติมค่ากลาง

2.2 Feature Engineering การสร้างตัวแปรใหม่ (26 Features)

เพื่อให้โมเดลเรียนรู้รูปแบบที่ซับซ้อนได้ดีขึ้น เราสร้าง features เพิ่มเติมจากข้อมูลดิบ 4 กลุ่มหลัก ได้แก่ Time Features, Lag Features, Rolling Average และ Interaction Terms

กลุ่ม	Feature	สูตรคำนวณ	เหตุผล
Time	month	df['date'].dt.month	บอก pattern รายเดือน
Time	dayofweek	df['date'].dt.dayofweek	วันธรรมดา vs วันหยุด (การจราจร)
Time	season	0=หนาว, 1=ร้อน, 2=ฝน	ฝุ่นสูงหน้าหนาว ต่ำหน้าฝน
Lag	pm10_lag1	df['pm10'].shift(1)	ฝุ่นเมื่อวานส่งผลต่อวันนี้
Lag	no2_lag1	df['no2'].shift(1)	ไอเสียเมื่อวาน (การจราจรเมื่อวาน)
Lag	o3_lag1 / so2_lag1 / co_lag1	shift(1) ทุกตัว	ประวัติสารมลพิษย้อนหลัง 1 วัน
Rolling	pm10_roll3	rolling(3).mean()	ค่าเฉลี่ย 3 วัน — trend ระยะสั้น
Rolling	pm10_roll7	rolling(7).mean()	ค่าเฉลี่ย 7 วัน — trend รายสัปดาห์
Rolling	no2_roll3 / o3_roll3 / o3_roll7	rolling(3 หรือ 7).mean()	แนวโน้มก๊าซมลพิษระยะสั้น-กลาง
Interaction	pm10_no2	pm10 × no2	ฝุ่น × ไอเสียรถ = ผลกระทบทวิคูณในเมือง
Interaction	o3_no2	o3 × no2	Photochemical Smog — ต้นเหตุฝุ่นทุติยภูมิ
Interaction	so2_co	so2 × co	ก๊าซโรงงาน × การเผาไหม้ =


on			มลพิษอุตสาหกรรม
----	--	--	-----------------

เหตุผลที่ต้องใช้ Feature Engineering:

- Lag Features: ฝุ่นในอากาศมีความต่อเนื่อง ถ้าเมื่อวานมีฝุ่นเยอะ วันนี้ก็มักจะเยอะตาม (Temporal Continuity)
- Rolling Average: ช่วยลด Noise และให้โมเดลเห็น Trend ระยะสั้น-กลาง ไม่ให้สับสนกับค่าผิดปกติในบางวัน
- Interaction Terms: ในความเป็นจริง PM2.5 เกิดจากปฏิกิริยาร่วมกันของก๊าซหลายชนิด การคูณกันทำให้โมเดลเข้าใจ Synergy Effect

2.3 Correlation Matrix

จาก Correlation Heatmap พบว่า pm10_lag1 มีความสัมพันธ์เชิงบวกกับ pm25 สูงที่สุด (~0.85) ตัวแปร season และ month มีความสัมพันธ์เชิงลบ สะท้อนว่าช่วงหน้าฝน (เดือนสูง) ฝุ่นมักจะต่ำกว่า



ภาพ : Feature Correlation Heatmap

ตารางสีแสดงความสัมพันธ์ระหว่าง Features ทุกคู่กับ pm25 สีแดงเข้ม = สัมพันธ์เชิงบวก (เพิ่มด้วยกัน) สีน้ำเงินเข้ม = สัมพันธ์เชิงลบ (สวนทางกัน) สีเทา = ไม่สัมพันธ์กัน pm10_lag1 และ pm10_roll3 มีสีแดงเข้มที่สุดกับ pm25 ยืนยันว่าเป็น Feature ที่สำคัญที่สุด

2.4 Determine Feature and Target

- Target (y): pm25 — ค่าที่โมเดลจะเรียนรู้และทำนาย
- Features (X): pm10, o3, no2, so2, co + features ที่สร้างขึ้นจาก Feature Engineering รวม 26 features

2.5 Train/Test Split

แบ่งข้อมูลออกเป็น 2 ชุด ตามหลัก Hold-out Method เพื่อพิสูจน์ว่าโมเดลสามารถ Generalize ได้กับข้อมูลใหม่ที่ไม่เคยเห็น ไม่ใช่แค่การท่องจำ (Overfitting)

ชุดข้อมูล	สัดส่วน	จำนวน (แถว)	วัตถุประสงค์
Train Set	80%	1,344	ให้โมเดลเรียนรู้หาค่า Coefficients (β)
Test Set	20%	336	วัดผลการพยากรณ์จริง — ข้อมูลที่โมเดลไม่เคยเห็น

พารามิเตอร์ที่ใช้:

- test_size=0.2 แบ่งข้อมูล 20% ไว้ทดสอบ
- random_state=42 ค่าสุ่มคงที่เพื่อให้ผลซ้ำได้ (Reproducibility)
- shuffle=True สลับลำดับข้อมูลก่อนแบ่ง เพื่อป้องกัน Bias จากข้อมูลเรียงตามวันที่

2.6 Feature Scaling — RobustScaler

ปรับขนาด feature ทุกตัวให้อยู่ในสเกลเดียวกัน เพื่อให้ตัวแปรที่มีค่าหน่วย (เช่น SO2) มีน้ำหนักพอกับตัวแปรหลักย่อย (เช่น PM10)

สูตร: $X_{\text{scaled}} = (X - \text{median}) / \text{IQR}$

เลือกใช้ RobustScaler แทน StandardScaler เพราะข้อมูลฝุ่นมี Outlier สูง (เช่น วันวิกฤตหมอกควัน) RobustScaler ใช้ median และ IQR จึงทนต่อ Outlier ได้ดีกว่า

บทที่ 3

Model Training

3.1 Linear Regression คืออะไร

Linear Regression คือโมเดลทางสถิติที่ใช้หาความสัมพันธ์เชิงเส้นระหว่างตัวแปรอิสระ (X) และตัวแปรตาม (y) โดยใช้หลักการ Ordinary Least Squares (OLS) ซึ่งหาค่าสัมประสิทธิ์ (β) ที่ทำให้ผลรวมของความคลาดเคลื่อนยกกำลังสองมีค่าน้อยที่สุด

ในโครงการนี้ใช้ Multiple Linear Regression (Many features $\rightarrow$ 1 output) เนื่องจากมีปัจจัยหลายตัวส่งผลต่อ PM2.5

3.2 สมการโมเดล


$$PM2.5 = \beta_0 + \beta_1(X_1) + \beta_2(X_2) + \dots + \beta_{26}(X_{26}) + \varepsilon$$

สมการที่โมเดลเรียนรู้ออกมา (5 ปัจจัยสำคัญที่สุด หลัง Scaling):

$$PM2.5 \approx 79.00$$

$$\begin{aligned} &+ 30.34 \times pm10_lag1 \text{ (ฝุ่น PM10 เมื่อวาน)} \\ &+ 6.97 \times pm10_roll3 \text{ (ค่าเฉลี่ย PM10 3 วัน)} \\ &+ 4.12 \times no2_roll3 \text{ (ค่าเฉลี่ย NO2 3 วัน)} \\ &+ 4.03 \times o3_roll7 \text{ (ค่าเฉลี่ย O3 7 วัน)} \\ &- 3.61 \times season \text{ (ฤดูกาล)} \end{aligned}$$

หมายเหตุ: ค่า X ทุกตัวถูก Scale ด้วย RobustScaler ก่อนเข้าโมเดล ค่า Coefficient จึงเปรียบเทียบกันได้โดยตรง



ภาพ : Top 15 Influential Features

แท่งแนวนอนแสดงค่า Coefficient ของแต่ละ Feature พบว่าค่า pm10_lag1 ยาวที่สุด (30.34) แสดงว่าค่า PM10 ของเมื่อวานมีอิทธิพลต่อ PM2.5 วันนี้มากที่สุด รองมาคือ pm10_roll3 และ no2_roll3

อันดับ	Feature	Coefficient (β)	ความหมาย
1	pm10_lag1	+30.34	pm10 เมื่อวาน ปัจจัยสำคัญที่สุด ฝุ่นมีความต่อเนื่อง
2	pm10_roll3	+6.97	ค่าเฉลี่ย pm10 3 วัน trend ฝุ่นระยะสั้น
3	no2_roll3	+4.12	ค่าเฉลี่ย no2 3 วัน การจราจร

			สะสม
4	o3_roll7	+4.03	ค่าเฉลี่ย o3 7 วัน สภาพอากาศ สะสม 1 สัปดาห์
5	season	-3.61	ฤดูกาล หน้าหนาวฝุ่นสูง หน้าฝน ฝุ่นต่ำ
6	no2_lag1	+3.39	no2 เมื่อวาน ไอลี่ยรวันก่อน
7	o3_no2	-2.43	Interaction: โอโซน × no2 ปฏิกิริยาเคมี
8	o3_roll3	-2.05	ค่าเฉลี่ย o3 3 วัน
9	month	-1.80	เดือน สะท้อน seasonality ราย ปี
10	co	+1.52	CO วันนี้ ไอลี่ยรยนต์
11	o3	+1.49	โอโซนวันนี้
12	o3_lag1	+1.48	โอโซนเมื่อวาน
13	pm10_roll7	-0.78	ค่าเฉลี่ย pm10 7 วัน
14	co_lag1	-0.57	CO เมื่อวาน
15	pm10_no2	-0.50	Interaction: pm10 × no2

3.3 ตัวอย่างการทำนาย

Input: pm10=80, o3=12, no2=15, so2=3, co=1.2, month=3 (มีนาคม),
season=0 (ฤดูแล้ง)

Output = Predicted PM2.5 $\approx 7.85 \mu\text{g}/\text{m}^3$

แม้ค่า PM10 จะสูงถึง 80 แต่โมเดลทาย PM2.5 ออกมาเพียง 7.85 เนื่องจากผลรวมของ Coefficient ทั้ง 26 ตัว บางตัวมีค่าเป็นลบ (เช่น season, month) และทุกตัวผ่านการ Scale แล้ว ทำให้ค่า Input จริงที่ป้อนเข้าโมเดลอาจกลายเป็นค่าลบเมื่อเทียบกับค่า Median ซึ่งดึงผลลัพธ์ลงมาจาก Intercept 79.00 จนเหลือ 7.85

บทที่ 4

Model Evaluation


4.1 ผลการประเมินโมเดล

Metric	ค่าที่ได้	สูตร	ความหมาย
R ² Score	0.9196 (92%)	$1 - \text{SS}_{\text{res}} / \text{SS}_{\text{tot}}$	โมเดลอธิบาย variance ของ pm25 ได้ 92%
RMSE	9.42 μg/m ³	$\sqrt{[\sum (y - \hat{y})^2 / n]}$	ค่าเฉลี่ยความผิดพลาด (โทษ outlier น้อย)
MAE	7.41 μg/m ³	$\sum y - \hat{y} / n$	ความผิดพลาดเฉลี่ย — ดีความง่ายกว่า RMSE

โมเดลมี $R^2 = 0.9196$ หมายความว่า ตัวแปรที่เลือกมาสามารถอธิบายความแปรปรวนของค่า PM2.5 ได้ถึง 92% และมีค่าความผิดพลาดเฉลี่ย (MAE) เพียง 7.41 μg/m³ ซึ่งถือว่าแม่นยำมากสำหรับข้อมูลสภาพอากาศที่มีความผันผวนสูง


4.2 Dashboard 4 ภาพ

Bangkok PM2.5 Prediction — Linear Regression Dashboard




ภาพที่ 1: Actual vs Predicted

เปรียบเทียบค่า PM2.5 จริง (แกน X) กับค่าที่โมเดลทำนาย (แกน Y) จุดสีฟ้าคือข้อมูล Test Set 336 วัน เส้นประแดงคือเส้น Perfect Fit (ทำนายถูก 100%) จุดเกาะกลุ่มตามเส้นสีแดงหนาแน่นยืนยันว่าโมเดลทำนายได้แม่นยำสูง




ภาพที่ 2: Residual Plot

แสดง Residual (ค่าจริง – ค่าทำนาย) เทียบกับค่าที่ทำนาย เส้นดำคือ $\text{Residual} = 0$ จุดสีส้มกระจายตัวสม่ำเสมอรอบเส้น 0 แสดงว่าโมเดลไม่มีความลำเอียง (Bias) ในช่วงค่าผู้ในระดับใดเป็นพิเศษ



ภาพที่ 3: Residual Distribution

Histogram ของค่า Residual ทั้งหมด กราฟเป็นรูปประฆังคว่ำสมมาตรรอบ 0 แสดงว่าส่วนใหญ่โมเดลทำนายพลาดน้อยมาก และไม่มี Systematic Error ด้านใดด้านหนึ่ง



ภาพที่ 4: Model Performance Metrics

แท่งกราฟสรุปคะแนน R^2 (0.9196), RMSE/100 (0.094), MAE/100 (0.074) แท่ง R^2 สูงมากแสดงความสามารถอธิบาย Variance ของข้อมูลได้ดี แท่ง RMSE/MAE ต่ำแสดง ความผิดพลาดต่ำ

สรุปโครงการ

โครงการนี้สร้างโมเดล Multiple Linear Regression เพื่อทำนายค่าฝุ่น PM2.5 ใน กรุงเทพมหานคร โดยใช้ข้อมูลคุณภาพอากาศ 7 ปี (2557–2564) จำนวน 1,680 แถว ที่มีค่า PM2.5 จากทั้งหมด 2,624 แถว

หลังจากทำ Feature Engineering สร้าง 26 Features (Time, Lag, Rolling, Interaction) โมเดลสามารถทำนาย PM2.5 ได้ด้วยความแม่นยำ $R^2 = 0.9196$ (92%) $RMSE = 9.42 \mu\text{g}/\text{m}^3$ และ $MAE = 7.41 \mu\text{g}/\text{m}^3$

ปัจจัยที่สำคัญที่สุดต่อการทำนายคือ pm10_lag1 (ค่า PM10 ของเมื่อวาน) แสดงให้เห็นว่าฝุ่นในอากาศมีความต่อเนื่องทางเวลา และ Feature Engineering ที่เพิ่มข้อมูลย้อนหลัง (Lag/Rolling) ช่วยเพิ่มความแม่นยำของโมเดลได้อย่างมีนัยสำคัญ